

Оценка кредитного риска методами Соловьёва-Панова

Панов Т.В. Соловьёв В.Д.

10 мая 2026 г.

Содержание

1	Описание данных	3
2	Чистка данных и анализ хвостов	4
2.1	Хвосты числовых переменных	4
2.2	Чувствительность к порогу возраста	5
2.3	Обработка пропусков и обоснование listwise drop	5
3	Кодирование переменных	6
4	EDA: описательные статистики и зависимости	7
4.1	Распределение значений в зависимости от Grade и истории	7
4.2	Корреляции	8
4.3	Графики парных зависимостей: мотивация и интерпретация	9
4.4	Условное Распределение признаков относительно loan_status	11
5	Диагностика мультиколлинеарности	11
6	Гипотезы о функциональных формах	12
7	Базовая логит-модель (M1) и предельные эффекты	14
7.1	Спецификация и оценивание	14
7.2	Результаты оценки и Odds Ratios	15
7.3	Подбор корректного порога вероятности	16
8	Альтернативные спецификации (M1–M7)	18
8.1	Сводная таблица коэффициентов	19
8.2	Обоснование выбора link-функции (Logit vs Probit vs Cloglog)	20
9	Тесты спецификации	21
9.1	LR-тесты вложенных моделей	22
9.2	Тесты Вальда на совместную значимость	23
9.3	Диагностика функциональной формы	23
9.4	Тест Хосмера-Лемешоу	23
9.5	Коррекция на множественное тестирование	24
9.6	Резюме по результатам тестирования спецификаций	24

10 Оценка предсказательной способности	25
10.1 Метрики качества и формулы	25
10.2 ROC и Precision-Recall кривые	26
10.3 Calibration plot	26
10.4 KS-statistic	27
10.5 Lift и Gain charts	28
11 Устойчивость и идентификация модели.	29
11.1 Сравнение типов стандартных ошибок	29
11.2 Bootstrap-доверительные интервалы	30
11.3 Sensitivity к порогу возраста	30
11.4 Sensitivity к обработке пропусков	31
11.5 Подвыборки — структурные сдвиги	31
11.6 Мультиколлинеарность и смещение	32
Заключение	32

1 Описание данных

Источник. Credit Risk Dataset by Lao Tse, Kaggle: <https://www.kaggle.com/datasets/laotse/credit-risk-dataset>.

Объём. $n = 32\,581$ наблюдение, 12 признаков. Целевая переменная `loan_status` $\in \{0, 1\}$: 1 — дефолт (заёмщик не вернул кредит), 0 — кредит погашен. Исходная доля дефолтов в выборке: $\bar{Y} = 0.2182$.

Ограничения данных, существенные для интерпретации:

1. **Страна и временной период не указаны.** По косвенным признакам (рейтинги `loan_grade` A–G, суммы в долларах) выборка стилизована под американский потребительский кредитный рынок. Точная локация и период сбора данных **неизвестны**.
2. **Аномально высокая доля дефолтов.** В выборке дефолт допускают $\bar{Y} \approx 21.8\%$ клиентов, тогда как в реальных кредитных портфелях эта доля обычно находится в диапазоне 2–8 %. Это указывает на вероятную искусственную балансировку выборки, при которой число наблюдений с дефолтом было увеличено для упрощения обучения моделей машинного обучения. Для логистической регрессии такое искажение пропорций приводит главным образом к смещению свободного члена ($\hat{\beta}_0$), тогда как оценки коэффициентов при признаках сохраняют интерпретацию относительного влияния факторов риска. Следовательно, модель позволяет корректно анализировать воздействие признаков, однако абсолютные значения прогнозируемых вероятностей ($\hat{p}$) могут быть систематически завышены.
3. **Смещение отбора (Reject Inference).** Модель обучается только на тех клиентах, которым банк *уже одобрил* кредит. Мы вообще не видим характеристик тех, кому было отказано. Из-за этого возникает сильное селективное смещение: если строгий кредитный комитет всё-таки выдал деньги человеку с «черной меткой» (например, с дефолтом в прошлом), значит, у этого клиента были какие-то мощные, но невидимые для нас плюсы (теневого доход, ценный залог). Из-за этого скрытого фильтра модель может сделать ошибочный статистический вывод, что плохая история — это признак надёжности. Содержательно этот эффект проявляется в анализе переменной `prev_default` (см. §8).
4. **Пространственный срез данных.** Данные не являются панельными. Это накладывает два серьёзных ограничения. Во-первых, мы не можем применить методы контроля индивидуальной ненаблюдаемой гетерогенности (модели с фиксированными эффектами, FE), чтобы отделить влияние характеристик заемщика от его «врожденной» склонности к риску. Во-вторых, отсутствие географических и временных идентификаторов означает, что мы не можем учесть влияние макроэкономических шоков или региональной специфики. Строгое эконометрическое допущение о независимости наблюдений (i.i.d.) может локально нарушаться из-за наличия этих скрытых кластеров (например, люди, бравшие кредит в год экономического спада), однако спецификация датасета не позволяет ввести соответствующие корректировки.

Описание и типы переменных исходного датасета.

Признак	Тип	Пропуски	% пропусков	Уникальных
person_age	int64	0	0.00	58
person_income	int64	0	0.00	4295
person_home_ownership	object	0	0.00	4
person_emp_length	float64	895	2.75	36
loan_intent	object	0	0.00	6
loan_grade	object	0	0.00	7
loan_amnt	int64	0	0.00	753
loan_int_rate	float64	3116	9.56	348
loan_status (целевая)	int64	0	0.00	2
loan_percent_income	float64	0	0.00	77
cb_person_default_on_file	object	0	0.00	2
cb_person_cred_hist_length	int64	0	0.00	29

Sanity-check. На уровне первичных статистик видны очевидные ошибки данных: максимальный возраст 144 года (хотя задокументированный максимум для человека — 122), стаж 123 года, доход скошен вправо до 6 000 000 \$.

2 Чистка данных и анализ хвостов

2.1 Хвосты числовых переменных

Чтобы понять, как обработать нефизические выбросы, проанализируем квантили правого хвоста переменных, в которых эти выбросы заметны.

Квантиль	person_age	person_income	person_emp_length
p50	26.0	55 000.0	4.0
p90	36.0	110 004.0	10.0
p95	40.0	138 000.0	13.0
p99	50.0	225 200.0	18.0
p99.9	66.0	648 000.0	25.0
max	144.0	6 000 000.0	123.0

Таблица 1: Распределение правых хвостов непрерывных предикторов




Рис. 1: Гистограммы и box-plot'ы для основных непрерывных предикторов. Видны изолированные значения `person_age > 100`, `person_emp_length > 40` и сильный правый хвост у `person_income`.

2.2 Чувствительность к порогу возраста

Оценим чувствительность выборки при отсечении экстремальных значений.

Порог <code>age</code> $\leq$	n	Удалено	$\bar{Y}$	$\overline{\text{age}}$	$p99(\text{age})$	$\max(\text{age})$
60	32 511	70	0.2181	27.64	48.0	60
80	32 574	7	0.2182	27.71	50.0	80
100	32 576	5	0.2182	27.72	50.0	94
120	32 576	5	0.2182	27.72	50.0	94
200 (без ограничения)	32 581	0	0.2182	27.73	50.0	144

Решение. Принимаем порог `age` ≤ 80 . Удаление 7 наблюдений (явные ошибки ввода — 84, 94, 123, 144) практически не меняет n и $\bar{Y}$, но избавляет выборку от технического шума. Для `emp_length` применяется естественное ограничение $\text{emp_length}_i \leq \text{age}_i - 14$, исключающее физически невозможный срок трудовой деятельности. Чувствительность $\hat{\beta}$ к выбору порога формально проверяется в §11.3.

2.3 Обработка пропусков и обоснование listwise drop

В исходной выборке присутствуют пропуски в двух признаках: `person_emp_length` (895 наблюдений, 2.75 %) и `loan_int_rate` (3116 наблюдений, 9.56 %). Было решено удалить все строки с пропусками. Это принципиально для всей последующей работы, и его правомерность обосновывается на трёх уровнях:

1. **Сохранение структуры целевой переменной.** Хотя суммарно удаляется $\approx 13.6\%$ исходной выборки ($n : 32\,581 \rightarrow 28\,631$), что является заметной долей, базовая частота дефолтов практически не меняется ($\bar{Y} : 0.218 \rightarrow 0.217$). Это является сильным первичным сигналом о том, что вероятность наличия пропуска не коррелирует напрямую с фактом дефолта.

2. **Теоретическое допущение о механизме пропусков.** Удаление строк с пропусками даёт несмещённые и состоятельные оценки коэффициентов $\hat{\beta}$ логистической регрессии в двух случаях:

- **MCAR** (Missing Completely At Random) — пропуск абсолютно случаен.
- **MAR** (Missing At Random) — вероятность пропуска может зависеть от наблюдаемых предикторов (например, стаж реже указывают люди определённого возраста), но не зависит от самой целевой переменной Y .

Смещение возникает только в случае **MNAR** (Missing Not At Random), когда пропуск обусловлен ненаблюдаемыми факторами, прямо связанными с риском дефолта. Поскольку строго доказать отсутствие MNAR на имеющихся данных невозможно, мы применяем эмпирическую проверку.

3. **Проверка устойчивости.** В §11.4 мы формально сравниваем три стратегии: удаление пропусков, заполнение медианой и метод фиктивных индикаторов. Коэффициенты при ключевых предикторах между этими тремя моделями совпадают в пределах 5–10 %. Такая устойчивость оценок говорит о том, что механизм пропусков близок к условиям MAR, и удаление наблюдений не вносит значимого смещения в выводы об относительном влиянии факторов риска.

Сводка этапов очистки.

Шаг	Действие	n	Удалено	$\bar{Y}$
0	Исходный датасет	32 581	0	0.2182
1	Фильтр $\text{age} \leq 80$	32 574	7	0.2182
2	Фильтр $\text{emp_length} \leq \text{age} - 14$	32 572	2	0.2182
3	Listwise drop пропусков	28 631	3 941	0.2166

Описательные статистики итоговой выборки для моделирования ($n = 28\,631$):

Признак	mean	std	min	25%	50%	75%	max
person_age	27.71	6.16	20.00	23.00	26.00	30.00	80.00
person_income	66 425.51	51 548.08	4 000	39 456	55 900	80 000	2 039 784
person_emp_length	4.78	4.04	0	2	4	7	41
loan_amnt	9 655.32	6 327.91	500	5 000	8 000	12 500	35 000
loan_int_rate	11.04	3.23	5.42	7.90	10.99	13.48	23.22
loan_percent_income	0.17	0.11	0.00	0.09	0.15	0.23	0.83
cb_person_cred_hist_length	5.79	4.04	2	3	4	8	30

3 Кодирование переменных

Для перебора альтернативных функциональных форм заранее готовим несколько кодировок ключевых регрессоров и складываем их в единый словарь `VAR_GROUPS` — любая модель в §7–§8 собирается как объединение нужных групп.

- `cb_person_default_on_file` $\rightarrow$ `prev_default` $\in \{0, 1\}$.
- `home` (ONE с MORTGAGE в качестве базового): `home_OTHER`, `home_OWN`, `home_RENT`.

- **intent** (ОHE с PERSONAL в качестве базового): `intent_DEBTCONSOLIDATION`, `intent_EDUCATION`, `intent_HOMEIMPROVEMENT`, `intent_MEDICAL`, `intent_VENTURE`.
- **loan_grade** в двух копиях: `grade_ord` $\in \{1, \dots, 7\}$ (для базовой модели и теста монотонности) и набор дамми `grade_B, \dots, grade_G` с базовым — `A`.
- **income** в трёх формах: `linear`, `log`, квантильные бины (5 квинтилей, `baseline` = нижний) — закрывает замечание про шкалу дохода.
- $\text{age2} = \text{age}^2$ — для теста квадратичной формы H1.
- `loan_int_rate` пока есть в данных, но решение об исключении принимается в §5 после VIF-диагностики.

4 EDA: описательные статистики и зависимости

4.1 Распределение значений в зависимости от Grade и истории

Grade	n	Default Rate	Mean Age	Mean Income	Mean LPI	Mean Rate
A	9 400	0.096	27.67	67 012	0.153	7.35 %
B	9 149	0.159	27.64	66 780	0.174	11.00 %
C	5 697	0.203	27.73	64 774	0.170	13.45 %
D	3 247	0.592	27.93	64 244	0.190	15.35 %
E	870	0.646	27.75	71 174	0.205	17.01 %
F	209	0.699	28.39	80 079	0.219	18.60 %
G	59	0.983	28.32	78 995	0.254	20.25 %

Таблица 2: Описательные статистики в разрезе кредитного рейтинга (`loan_grade`). Default rate монотонно растёт от 9.6 % до 98 %.

Кредитная история	n	Def. Rate	Age	Income	Grade(ord)	LPI
no prior default	23 529	0.182	27.68	66 455	1.936	0.168
prior default	5 102	0.377	27.83	66 288	3.575	0.178

Таблица 3: Описательные статистики в разрезе наличия прошлых дефолтов.

Что видно. Как и ожидается, Default rate **монотонно растёт** с `grade` (от 9.6% до 98%). Это свидетельствует о том, что рейтинг заемщика является важным признаком в модели, поскольку он довольно точно описывает поведение заемщика по отношению к новому долгу (вернет он его в итоге или нет). Средняя ставка (`loan_int_rate`), названная здесь как (**Mean Rate**) строго привязана к рейтингу, что говорит о том, что рейтинг заемщика существенным образом определяется по тому был у него ранее дефолт или нет. Видно также, что Grade заемщика не зависит от его возраста и слабо зависит от зарплаты, зато прослеживается четкая зависимость от LPI, что говорит о том, что более ненадежные заемщики более склонны к тому, чтобы брать заём, размер которого является значительной частью их зарплаты.

4.2 Корреляции




Рис. 2: Корреляционная матрица числовых признаков.

Ключевые корреляции:

- $\text{person_age} \leftrightarrow \text{cb_person_cred_hist_length} \approx 0.86$ — (длина кредитной истории растёт с возрастом), что является весьма логичной корреляцией.
- $\text{loan_int_rate} \leftrightarrow \text{grade_ord} \approx 0.93$ — как и было замечено выше в рассуждениях про grade — рейтинг практически полностью определяет ставку. При таком большом коэффициенте корреляции среди признаков неизбежно возникнет мультиколлинеарность, которую мы будем должны устранить далее.
- $\text{grade_ord} \leftrightarrow \text{loan_status} \approx 0.38$ — мы понимаем, что с ростом grade действительно увеличивается вероятность дефолта заемщика. Как было отмечено выше — именно поэтому grade является, предположительно, ключевым признаком нашей модели.
- $\text{loan_percent_income} \leftrightarrow \text{loan_status} \approx 0.38$ — сигнал, свидетельствующий о том, что loan percent income также является важным признаком в модели.
- $\text{grade_ord} \leftrightarrow \text{prev_default} \approx 0.54$ — так же соответствует предположению выше. Таким образом, мы понимаем на основании каких данных сотрудниками банка принимается решение о присвоении того или иного рейтинга.
- $\text{loan_int_rate} \leftrightarrow \text{loan_status} \approx 0.34$ — сильная корреляция, связанная с тем, что loan int rate в значительной степени определяется по grade заемщика.

4.3 Графики парных зависимостей: мотивация и интерпретация

Зачем строим эти графики. Bivariate-плот — это возможность посмотреть на график зависимости целевой переменной от каждого признака, без привязки к конкретной модели, что позволит нам сделать некоторые предположения о функциональной форме модели, добавить новые признаки. Таким образом, гипотезы, которые рассматриваются в параграфе 6, в значительной степени опираются на эмпирические зависимости, которые удастся заметить на данном этапе. Для каждого предиктора, принимающего вещественные значения, то есть непрерывной переменной X_j строится

$$\bar{Y}_k = \frac{1}{|B_k|} \sum_{i \in B_k} Y_i,$$

где B_k — k -й дециль X_j . Если теоретическая форма ($\hat{\beta}_j X_j$) совпадает с эмпирическим профилем — выбор формы оправдан; если не совпадает — это сигнал к введению нелинейностей (квадрат, логарифм, интеракция).




Рис. 3: Bivariate-plot по децилям ключевых признаков (горизонтальная линия — общая base rate $\bar{Y} = 0.217$).

Наблюдения по данным графикам.

- **person_age**: мы видим, что убывание конечно не монотонное, но и возможную квадратическую зависимость тут не видно, поскольку на последнем дециле наша зависимость показывает убывание. Что хочется отметить, так это то, что последний дециль у нас включает в себя заемщиков с большим разбросом возрастов — от 34 и до максимального 80. Поэтому квадратическая зависимость может и есть, но на дециле мы ее не поймаем. Поэтому в дальнейшем проведем статистический тест, который поможет нам выяснить стоит ли добавлять член с age^2 в модель;
- **log_income**: практически монотонно убывает (есть несколько децилей, на которых есть возрастание, однако это возрастание незначительное, относительно убывания на других децилях); форма поддерживает логарифмическую шкалу, что в дальнейшем станет основой для гипотезы (H2).

- **loan_percent_income**: пологий рост в нижних децилях, **резкий скачок в верхних** (выше 7-го дециля кривая идёт почти вертикально). Это убедительный аргумент за нелинейность, которая отражена в гипотезе Н3 или интеракцию $lpi \times grade$ — проверим в М5.
- **loan_int_rate**: монотонно возрастает, тоже пологий подъем как и в случае **loan_percent_income** — но этот признак сильно коррелирует с **grade** (а именно, $\rho = 0.93$), поэтому неудивительно, что график для **grade_ord** так похож на этот. В дальнейшем мы оставим только один из этих признаков.
- **cb_person_cred_hist_length**: (default rate сначала резко падает, потом на 4-5 дециле происходит некоторый скачок и спуск, потом незначительное возрастание). **Интерпретация**: первый дециль соответствует самым “новым” заёмщикам с историей ≤ 2 лет — у них ещё недостаточно информации для оценки риска, и default rate выше базы. Далее, для клиентов из 2-3-го дециля, у банка появляется необходимая база и они уже не доверяют деньги ненадежным клиентам. Дальнейшие колебания графика сложно интерпретировать и более подробному исследованию этого фактора будет посвящена гипотеза Н8. Потому что истинная зависимость, вероятнее всего — *не линейная*, а скорее *ступенчатая* (“короткая vs длинная история”).
- **grade_ord**: грубо линейный рост в логит-шкале от А к D, потом резкий скачок — мотивирует тест линейности по **grade** в §9.
- **loan_amnt**: Зависимость также не похожа на линейную, а скорее на квадратичную.
- **person_emp_length**: зависимость очень похожая на **person_age**, что неудивительно, так как эти 2 признака коррелированы.




Рис. 4: Default rate по категориальным признакам.

Из данных столбчатых диаграмм мы делаем вывод, что собственная квартира, как и ипотека, не дает высокого default_rate, в то время как аренда и другое (либо отсутствие жилья, либо жизнь с родителями, либо что-то еще) повышает риск дефолта заемщика. Очевидно, что взятие кредита как рефинансирование старых кредитов также не приводит к чему-то хорошему, о чем свидетельствует 3-я диаграмма. 1-ая диаграмма еще раз подтвердила нашу гипотезу о том, что банковские рейтинги очень эффективны.

4.4 Условное Распределение признаков относительно loan_status




Рис. 5: Распределение `person_age`, `loan_percent_income`, `loan_amnt` относительно `loan_status`

Как мы видим, `person_age`, `loan_amnt` имеют практически одинаковое распределение при разных `loan_status`. Это наталкивает нас на мысль, что коэффициенты в модели при данных переменных будут нулевыми, так как они слабо объясняют целновую переменную. А вот распределение `loan_percent_income` уже отличается. Люди, которые в будущем объявят дефолт намного чаще берут в долг суммы, которые составляют значительную долю в их заработной плате.

5 Диагностика мультиколлинеарности

Для выявления потенциальной мультиколлинеарности среди предикторов мы используем фактор инфляции дисперсии (VIF). Этот показатель оценивает, во сколько раз увеличивается дисперсия оценки коэффициента из-за линейной зависимости данного признака с остальными переменными модели.

Формула расчета имеет вид:

$$\text{VIF}_j = \frac{1}{1 - R_j^2},$$

где R_j^2 — коэффициент детерминации вспомогательной OLS-регрессии переменной X_j на все остальные регрессоры. Традиционно значения VIF, превышающие эвристический порог 5 (в некоторых источниках — 10), служат сигналом о наличии сильной мультиколлинеарности.

Техническое замечание. При расчёте VIF дизайн-матрица обязательно должна включать константу. В противном случае показатели для нецентрированных переменных будут искусственно завышены из-за смещения начала координат. Разумеется, итоговые значения VIF мы анализируем только для содержательных предикторов.

VIF с loan_int_rate		VIF без loan_int_rate	
Признак	VIF	Признак	VIF
grade_ord	8.21	loan_amnt	5.45
loan_int_rate	7.85	loan_percent_income	5.13
loan_amnt	5.46	person_age	4.43
loan_percent_income	5.13	cb_person_cred_hist_length	4.36
person_age	4.43	log_income	4.34
cb_person_cred_hist_length	4.36	intent_EDUCATION	1.75
log_income	4.35	intent_MEDICAL	1.71
...	...	...	...
среднее ≈ 3.3		grade_ord падает с 8.21 до 1.47	

Таблица 4: VIF до и после исключения процентной ставки.

Анализ и принятое решение. Как видно из левой части таблицы, наибольшие значения VIF демонстрируют переменные `grade_ord` (8.21) и `loan_int_rate` (7.85). Оба показателя заметно превышают пороговое значение. Это вполне ожидаемо: как мы уже отмечали на этапе EDA (§4.3), процентная ставка практически полностью определяется кредитным рейтингом заемщика (корреляция $\rho \approx 0.95$). Следовательно, около 80 % дисперсии каждой из этих переменных дублируется. Совместное включение их в модель приведет к вычислительной неустойчивости и сильно затруднит интерпретацию коэффициентов.

В связи с этим было принято решение исключить `loan_int_rate` из базовой спецификации, оставив рейтинг как более фундаментальный показатель риска. Правая часть таблицы подтверждает корректность этого шага: после удаления ставки VIF для `grade_ord` падает до 1.47, а явные признаки мультиколлинеарности в модели исчезают.

Чтобы наглядно проиллюстрировать влияние этой коллинеарности на практике, в §8 мы оценим альтернативную спецификацию (M6), в которой искусственно сохраним обе переменные. Мы увидим классическое проявление данного эффекта: при добавлении ставки коэффициент при `grade_ord` падает почти в два раза, так как переменные начинают делить между собой один и тот же объясняющий сигнал.

6 Гипотезы о функциональных формах

В соответствии с методологией эконометрического анализа, ожидаемые эффекты и функциональные формы предикторов специфицируются *a priori*, до начала оценивания моделей. Ниже сформулированы базовые гипотезы относительно влияния ключевых факторов на целевую переменную.

(В таблице ниже знак «+» означает ожидаемую положительную связь с вероятностью дефолта, «−» — отрицательную).

#	Переменная	Знак	Форма	Обоснование
H1	age, age ²	+, −	lin + quad	Предполагается U-образный эффект жизненного цикла: повышенный риск у молодых и пожилых заемщиков. Однако результаты предварительного EDA (§4.3) показали сомнительную статзначимость.
H2	log(income)	−	log	Влияние дохода носит скорее относительный чем абсолютный характер. Это обосновывает лог-линейную спецификацию.
H3	loan_percent_income	+, нелинейно	linear + interaction lpi × grade	Высокая долговая нагрузка увеличивает риск неплатежеспособности. Анализ распределений выявил резкий структурный сдвиг в верхних децилях, что требует введения нелинейности.
H4	loan_grade	+, нелинейно	dummy > ordinal	Неравномерные скачки частоты дефолтов между категориями обосновывают использование дамми-переменных вместо порядковой шкалы.
H5	prev × log(income)	−	interaction	Эффект наличия дефолта в прошлом может быть частично скомпенсирован высоким текущим доходом заемщика.
H6	prev_default	+, но слабее с контролем grade	dummy	Наличие прошлых дефолтов увеличивает риск. Однако ожидается, что при включении рейтинга, который вбирает в себя этот сигнал, остаточный эффект переменной заметно ослабнет.
H7	intent	смешанные	dummy	Цели кредита маркируют финансовое состояние: консолидация долгов и медицина отражают стрессовые ситуации (+), тогда как образование или бизнес ассоциируются с надежностью (−).
H8	cred_hist	≈ 0	linear	При контроле на возраст длина кредитной истории несет мало доп. информации. Ожидается, что предельный эффект будет статистически незначимым.

Влияние статуса владения недвижимостью. Ожидается, что аренда жилья (`home_RENT`) выступит фактором повышенного риска по сравнению с ипотекой (`MORTGAGE`). При этом данный эффект может частично объясняться разницей в благосостоянии: мы предполагаем, что при включении в модель переменной `log(income)` часть этого риска будет поглощена эффектом дохода. Напротив, владение домом без обременений (`home_OWEN`) служит сильным независимым маркером финансовой стабильности и накопленного капитала, поэтому ожидается, что данный фактор сохранит значимый отрицательный знак при любом наборе контрольных переменных.

Дизайн тестирования гипотез. Дальнейший анализ выстроен таким образом, чтобы каждая из заявленных гипотез была проверена в соответствующей спецификации:

- **Базовая спецификация (M1, §7):** оценивает первичные эффекты (H7, статус жилья) и проверяет гипотезу об избыточности кредитной истории (H8).
- **Альтернативные спецификации (M2–M7, §8):** используются для проверки нелинейностей и структурных сдвигов. В частности, гипотеза о возрасте (H1) тестируется в модели M2 (LR-тест), выбор шкалы дохода (H2) — в моделях M3a/M3b (сравнение по AIC), эффект рейтинга (H4) — в M4 (Wald-тест на равенство эффектов), а сложные взаимовлияния долговой нагрузки и прошлых дефолтов (H3, H5) — в спецификации M5.
- Влияние переменной `prev_default` (H6) будет детально разобрано при сопоставлении моделей M1 и M7 через призму проблемы смещения отбора.

7 Базовая логит-модель (M1) и предельные эффекты

7.1 Спецификация и оценивание

Модель. Постулируется параметрическая форма условной вероятности дефолта:

$$\Pr(Y_i = 1 \mid X_i) = \Lambda(X_i^\top \beta) = \frac{e^{X_i^\top \beta}}{1 + e^{X_i^\top \beta}}, \quad (1)$$

Оценивание — MLE. Лог-правдоподобие

$$\ell(\beta) = \sum_{i=1}^n [Y_i \log \Lambda(X_i^\top \beta) + (1 - Y_i) \log(1 - \Lambda(X_i^\top \beta))], \quad \hat{\beta} = \arg \max_{\beta} \ell(\beta).$$

Если наша модель корректно специфицирована и наша выборка — i.i.d. $\sqrt{n}(\hat{\beta} - \beta_0) \xrightarrow{d} \mathcal{N}(0, I^{-1})$.

Robust SE. Используем так называемое **HC1** для оценки ковариационной матрицы:

$$\widehat{\text{Var}}_{\text{HC1}}(\hat{\beta}) = \frac{n}{n - k} (X^\top W X)^{-1} X^\top \hat{U} X (X^\top W X)^{-1}, \quad (2)$$

где $W = \text{diag}(\hat{p}_i(1 - \hat{p}_i))$, $\hat{U} = \text{diag}((Y_i - \hat{p}_i)^2)$.

Базовая спецификация M1:

$X = (\text{const}, \text{age}, \text{emp_length}, \text{loan_amnt}, \text{lpi}, \text{cred_hist}, \log(\text{income}), \text{home dummies}, \text{intent dummies}, \text{grade_ord}, \text{prev})$.

7.2 Результаты оценки и Odds Ratios

Поскольку $\frac{p}{1-p} = \exp(X^\top \beta)$, увеличение X_j на единицу умножает шансы (odds) на $\exp(\beta_j)$. Можно рассматривать для оценки **Average Partial Effect (APE)** или **Marginal Effect at Means (MEM)**. Мы остановились на APE, так как MEM дает некоторого несуществующего заемщика, причем некоторые значения вроде `home_RENT` = 0.5 для категориальных переменных, не имеют смысла, что также дает преимущество усреднению через APE перед MEM. (APE) для непрерывного X_j :

$$\text{APE}_j = \frac{1}{n} \sum_{i=1}^n \hat{p}_i (1 - \hat{p}_i) \hat{\beta}_j.$$

Признак	$\hat{\beta}$	p-val	OR	OR 95 % CI	APE	APE p-val
const	5.9759	<0.001	393.80	[57.36, 2703.81]	—	—
person_age	−0.0070	0.260	0.99	[0.98, 1.01]	−0.0008	0.260
person_emp_length	−0.0020	0.701	1.00	[0.99, 1.01]	−0.0002	0.701
loan_amnt	−0.0000	0.570	1.00	[1.00, 1.00]	−0.0000	0.570
loan_percent_income	8.0785	<0.001	3224.43	[1402.69, 7412.17]	0.8691	<0.001
cb_person_cred_hist_length	0.0052	0.589	1.01	[0.99, 1.02]	0.0006	0.589
log_income	−1.0546	<0.001	0.35	[0.29, 0.42]	−0.1135	<0.001
home_OTHER	0.4472	0.097	1.56	[0.92, 2.65]	0.0481	0.097
home_OWN	−1.6983	<0.001	0.18	[0.15, 0.23]	−0.1827	<0.001
home_RENT	0.7146	<0.001	2.04	[1.88, 2.23]	0.0769	<0.001
intent_DEBTCONSOLIDATION	0.6077	<0.001	1.84	[1.63, 2.07]	0.0654	<0.001
intent_EDUCATION	−0.2522	0.0001	0.78	[0.69, 0.88]	−0.0271	0.0001
intent_HOMEIMPROVEMENT	0.6866	<0.001	1.99	[1.73, 2.29]	0.0739	<0.001
intent_MEDICAL	0.4124	<0.001	1.51	[1.34, 1.70]	0.0444	<0.001
intent_VENTURE	−0.4799	<0.001	0.62	[0.55, 0.70]	−0.0516	<0.001
grade_ord	0.9268	<0.001	2.53	[2.43, 2.62]	0.0997	<0.001
prev_default	−0.1187	0.011	0.89	[0.81, 0.97]	−0.0128	0.011

$n = 28\,631$, $McFadden R^2 = 0.340$, $AIC = 19\,776$, $BIC = 19\,917$; $HC1 SE$.

Таблица 5: Логит-коэффициенты, OR и APE для базовой модели M1.

Ключевые выводы базовой модели.

- **H2 (log income):** удвоение дохода ($\Delta \log = 0.69$) умножает odds на $e^{0.69 \cdot (-1.05)} \approx 0.49$ — риск уменьшается почти в 2 раза. Гипотеза подтверждается.
- **H3 (lpi):** $\hat{\beta} = 8.08$, $\Delta \text{lpi} = 0.10$; odds = $e^{0.808} \approx 2.24$, то есть рост долговой нагрузки на 10 п.п. увеличивает шансы дефолта в 2.24 раза.
- **H4 (grade_ord):** OR = 2.53 на каждый шаг grade. Тест линейности — в §9 (отвергает в пользу дамми).
- **H7 (intent):** все знаки совпали с предсказанными (DEBTCONSOL/MEDICAL/HOMEIMP > 0, EDUC/VENTURE < 0).
- **H_OWN, H_RENT:** собственники в ≈ 5.5 раз безопаснее ипотечников; арендаторы в 2 раза рискованнее.
- **H8:** $\hat{\beta}_{\text{cred_hist}} = 0.005$, $p = 0.59$ — не отвергаем нулевую гипотезу. Это согласуется с интерпретацией bivariate-графика в первом дециле: сигнал для модели получаем только на коротких кредитных историях.

- **Замечание о масштабах.** `loan_amnt` выражен в количестве долларов за год, поэтому коэффициент -0.0000 выглядит маленьким, но это не означает, что эффект от этого признака нулевой. Экономически эффект может присутствовать. Логарифмирование (как сделано с `income`) решает эту проблему масштаба.
- **Заметка к рейтингу G:** в этой категории всего $n = 59$ наблюдений, поэтому оценки эффектов имеют высокую дисперсию.

Неподтвержденная гипотеза H6, связанная с `prev_default`. Прогнозировали по H6 положительный эффект. Но получен коэффициент: $\hat{\beta} = -0.119$, $OR = 0.89$, $p = 0.011$ — знак сменился на отрицательный. Подробный Разбор этой ситуации, называемый парадоксом Симпсона (Simpson's paradox, OVB через grade и selection bias через reject inference) приведён в 8 параграфе после сравнения M1 и M7 (без grade), а также отмечен в разделе 11 в самом конце.

7.3 Подбор корректного порога вероятности

Все метрики таблицы 5 посчитаны in-sample — это даёт нам *оптимистичную* оценку. Но для подбора модели нам важно разделить выборку на train и test. Делаем разделение 80/20 с сохранением пропорций классов.

$$n_{\text{train}} = 22\,904, \quad n_{\text{test}} = 5\,727, \quad \bar{Y}_{\text{train}} = \bar{Y}_{\text{test}} = 0.217.$$

$AUC_{\text{train}} = 0.8690,$	$AUC_{\text{test}} = 0.8713$
--------------------------------	------------------------------

Признаков переобучения модели не обнаружено, так как на тестовой выборке качество даже чуть лучше получается.

Зачем нужен подбор порога. Решение “выдать кредит / отказать” принимается по правилу $\hat{Y}_i = \mathbb{I}[\hat{p}_i > t]$. Порог t должен выбираться таким образом, чтобы был достигнут в некотором смысле баланс между FN, FP. Говоря фразу “В некотором смысле мы подразумеваем, что в кредитном скоринге важнее, конечно, FN, но и слишком большой FP нас устраивать не будет — у банка не будет возможности на ком-то заработать денег, если всем отклонять запросы в займе. Коротко это описывается такими пунктами:

- **False Negative** ($\hat{Y} = 0$ при $Y = 1$) — выдан кредит дефолтнику → банк теряет деньги. Стоимость FN *высокая*.
- **False Positive** ($\hat{Y} = 1$ при $Y = 0$) — отказ хорошему клиенту → банк теряет потенциальную прибыль. Стоимость FP *ниже*.

Порог по умолчанию $t = 0.5$ часто не оптимален; для recall-ориентированного отбора порог понижают. Поэтому мы проведем кросс-валидацию, в ходе которой выявим оптимальный порог для нашей задачи:

t	precision	recall	F1	TP	FN	FP	TN
0.20	0.4929	0.8139	0.6140	1010	231	1039	3447
0.25	0.5345	0.7671	0.6300	952	289	829	3657
0.30	0.5772	0.7260	0.6431	901	340	660	3826
0.35	0.6129	0.6737	0.6418	836	405	528	3958
0.40	0.6586	0.6342	0.6461	787	454	408	4078
0.45	0.6911	0.5770	0.6289	716	525	320	4166
0.50	0.7226	0.5205	0.6052	646	595	248	4238

Таблица 6: Метрики на тестовой выборке при разных порогах отсечения для M1.

Интерпретация таблицы. С ростом t precision увеличивается, recall падает. **Фиксируем** $t = 0.35$ как “recall-ориентированный” порог: он балансирует precision и recall с упором на recall, что соответствует банковской cost-структуре $FN \gg FP$. При $t = 0.35$ модель ловит 67.4% дефолтников. F1 метрика для данного порога также одна из наилучших. В дальнейших сравнениях моделей (метрики precision/recall/F1 считаются именно при $t = 0.35$).




Рис. 6: ROC-кривая M1 на train и test. Чёрная точка — порог $t = 0.35$.

Интерпретация ROC-кривой. Кривая показывает все возможные пары (FPR, TPR) при разных порогах. Чем выше и левее кривая, тем лучше модель разделяет классы. Идеал — верхний левый угол; случайный классификатор лежит на диагонали. Конкретно для M1: $AUC_{train} \approx AUC_{test}$ (разница в 3-м знаке); видно, что модель уже далеко не случайно принимает решение, но и не идеальна, хотя метрика AUC принимает весьма хорошие значения. $AUC_{test} = 0.871$ ($Gini = 2 \cdot AUC - 1 = 0.74$). Точка $t = 0.35$ соответствует $recall \approx 0.67$, $FPR \approx 0.12$ — модель ловит большинство дефолтников при умеренной доле ложных тревог.

8 Альтернативные спецификации (М1–М7)

Мотивация выбора спецификаций. Для проверки устойчивости базовой модели и изолированной оценки влияния отдельных факторов мы оцениваем серию альтернативных спецификаций (М1–М7). В каждой последующей модели относительно базовой (М1) изменяется строго один блок регрессоров. Такой пошаговый подход позволяет сопоставлять каждую модификацию с проверяемой гипотезой и выявлять чувствительность коэффициентов к смене функциональной формы.

#	Изменения относительно базовой (М1)	Аналитическая цель (проверяемая гипотеза)
М1	Базовая спецификация (см. §7)	Точка отсчёта.
М2	Добавление age^2	Н1: проверка гипотезы о $\cap$ -образном влиянии возраста.
М3а	Замена $\log(\text{income})$ на линейную форму	Н2: оценка чувствительности результатов к выбору шкалы дохода.
М3б	Замена $\log(\text{income})$ на квинтили	Н2: проверка влияния дохода без предположения о монотонности.
М4	Замена <code>grade_ord</code> на дамми $D_B, \dots, D_G$	Н4: проверка гипотезы о нелинейном влиянии кредитного рейтинга.
М5	М4 + интеракции $\text{lpi} \times \text{grade}$ и $\text{prev} \times \log(\text{income})$	Н3, Н5: выявление структурных сдвигов и взаимовлияния факторов риска.
М6	М1 + включение <code>loan_int_rate</code>	Эмпирический стресс-тест на последствия мультиколлинеарности (из §5).
М7	М1 без переменной <code>grade_ord</code>	Оценка изолированного вклада кредитного рейтинга в объясняющую способность модели.

Таблица 7: Структура оцениваемых спецификаций.

8.1 Сводная таблица коэффициентов

Признак	M1	M2	M3a	M3b	M4	M5	M6	M7
const	5.976*** (0.983)	6.398*** (1.009)	-5.503*** (0.160)	-5.001*** (0.164)	7.332*** (0.992)	9.661*** (1.022)	6.369*** (0.995)	10.455*** (0.908)
person_age	-0.007 (0.006)	-0.038** (0.017)	-0.009 (0.006)	-0.008 (0.006)	-0.010 (0.006)	-0.010 (0.006)	-0.008 (0.006)	-0.006 (0.006)
age2		0.000** (0.000)						
loan_percent_income	8.079*** (0.425)	8.090*** (0.425)	13.001*** (0.278)	10.991*** (0.394)	8.452*** (0.426)	13.079*** (0.541)	8.037*** (0.425)	5.582*** (0.376)
log_income	-1.055*** (0.090)	-1.049*** (0.090)			-1.059*** (0.092)	-1.349*** (0.096)	-1.064*** (0.091)	-1.287*** (0.084)
grade_ord	0.927*** (0.019)	0.927*** (0.019)	0.941*** (0.019)	0.930*** (0.019)			0.534*** (0.038)	
prev_default	-0.119** (0.047)	-0.118** (0.047)	-0.114** (0.046)	-0.114** (0.046)	0.012 (0.055)	-3.451*** (0.934)	-0.115** (0.047)	1.126*** (0.041)
prev_x_log_inc						0.319*** (0.086)		
loan_int_rate							0.050*** (0.016)	
<i>n</i>	28631	28631	28631	28631	28631	28631	28631	28631
log <i>L</i>	-9871	-9869	-9958	-9892	-9532	-9403	-9866	-11313
AIC	19776	19775	19950	19823	19108	18853	19769	22658
BIC	19917	19924	20090	19989	19289	19051	19917	22790
McFadden <i>R</i> ²	0.340	0.340	0.334	0.339	0.363	0.372	0.341	0.244
Out-of-sample (test, <i>t</i> = 0.35):								
AUC test	0.871	0.871	0.867	0.869	0.877	0.883	0.871	0.819
Precision test	0.613	0.612	0.619	0.617	0.655	0.652	0.617	0.583
Recall test	0.674	0.673	0.664	0.670	0.691	0.724	0.673	0.607
F1 test	0.642	0.641	0.641	0.642	0.672	0.686	0.644	0.595

Показаны только ключевые предикторы. *** $p < 0.01$, ** $p < 0.05$, * $p < 0.1$.

Таблица 8: Сравнение спецификаций M1–M7 с диагностикой и out-of-sample метриками при пороге отсечения $t = 0.35$.

Согласованность информационных критериев и метрик качества. Данные таблицы 8 демонстрируют консистентность in-sample и out-of-sample оценок: спецификация с минимальным значением информационного критерия (M5: AIC = 18 853) одновременно обеспечивает наивысшие показатели метрик на тестовой выборке (AUC = 0.883, Recall = 0.724). Модели строго ранжируются по обоим классам метрик: M5 $\succ$ M4 $\succ$ M2 $\approx$ M1 $\succ$ M3b $\succ$ M3a $\succ$ M7. Это подтверждает целесообразность использования AIC/BIC в качестве первичного фильтра с последующей верификацией на hold-out выборке.

Устойчивые эффекты Во всех спецификациях сохраняется направление и статистическая значимость ключевых предикторов: показатель долговой нагрузки всегда положителен (loan_percent_income), доход (log_income) и владение недвижимостью (home_OWN) строго отрицательны. Длина кредитной истории стабильно остается незначимой (cb_person_cred_hist_length), что подтверждает гипотезу H8.

Ключевые структурные наблюдения:

- **Эффект шкалы дохода.** Логарифмическая форма (M1) демонстрирует существенно лучший fit (AIC ниже на 174 единицы), чем линейная спецификация (M3a). Это подтверждает закон об убывающей предельной полезности дохода.
- **Процентная ставка и коллинеарность (M6).** При добавлении переменной loan_int_rate коэффициент при кредитном рейтинге (grade_ord) падает с 0.93 до 0.53. Это проявление мультиколлинеарности ($\rho = 0.95$). Данный тест полностью подтверждает корректность решения об исключении ставки, принятого в §5.

- **Смещение отбора и парадокс Симпсона.** Особого внимания заслуживает переменная наличия прошлых дефолтов (`prev_default`). В базовой спецификации (M1) ее знак парадоксальным образом оказывается отрицательным (-0.119). Однако при исключении кредитного рейтинга (M7) знак меняется на ожидаемый положительный ($+1.126$). Это не ошибка модели, а строгое проявление двух эконометрических эффектов:
 1. **Смещение пропущенной переменной.** Рейтинг вбирает в себя основной негативный сигнал о прошлой истории. При исключении рейтинга (M7) переменная `prev_default` аккумулирует весь этот штрафной эффект на себя.
 2. **Смещение отбора.** Модель оценивается на усеченной выборке — только на клиентах, которым банк *уже одобрил* кредит ($S = 1$). Если заемщик с дефолтом в прошлом все же получил одобрение, это означает наличие у него сильных ненаблюдаемых позитивных характеристик ($\mathbb{E}[\varepsilon \mid \text{prev} = 1, S = 1] > \mathbb{E}[\varepsilon \mid \text{prev} = 0, S = 1]$). В модели M1 переменная `prev_default` улавливает именно эту позитивную селекцию, которая перевешивает остаточный штраф. Формально этот механизм будет подтвержден анализом подвыборок в §11.5.
- **Сложные взаимодействия (M5).** Введение интеракций существенно улучшает объясняющую способность модели. Важно отметить, что прямая интерпретация коэффициента $\beta = -3.451$ при `prev_default` в данной спецификации затруднена, поскольку она отражает эффект при $\log(\text{income}) = 0$ (доход в 1\$), что лежит за пределами носителя данных. Для оценки реального влияния следует использовать расчет средних предельных эффектов (APE).

8.2 Обоснование выбора link-функции (Logit vs Probit vs Cloglog)

Традиционно в логистической регрессии используется функция распределения $\Lambda(z) = e^z / (1 + e^z)$, связывающая линейный предиктор $X^\top \beta$ и вероятность p . Однако для проверки устойчивости результатов к выбору функциональной формы мы дополнительно оцениваем модель M5 с альтернативными link-функциями:

- **Probit** (функция связи — стандартная нормальная CDF $\Phi(z)$). Симметрична, но обладает более «лёгкими» хвостами, что делает переход в области экстремальных вероятностей более крутым.
- **Cloglog** (complementary log-log: $1 - \exp(-e^z)$). В отличие от предыдущих, асимметрична по построению. Часто применяется в моделях выживаемости, так как предполагает, что вероятность наступления события растёт быстрее при больших значениях линейного предиктора.

Методологическое замечание. Коэффициенты $\hat{\beta}$, полученные с использованием разных link-функций, не подлежат прямому сравнению из-за различия в шкалах. Сопоставление моделей проводится на основе предельных эффектов (APE) и out-of-sample метрик качества классификации (AUC, Brier score, log-loss).

Link-функция	AUC	Precision	Recall	F1	Brier ↓	log-loss ↓
Logit (выбранная)	0.8825	0.652	0.724	0.686	0.0976	0.3305
Probit	0.8810	0.639	0.724	0.679	0.0995	0.3381
Cloglog	0.8827	0.676	0.710	0.693	0.0959	0.3317

Таблица 9: Сравнение link-функций на спецификации М5 (тестовая выборка, $t = 0.35$).

Выводы и итоговый выбор:

1. Различия в показателях AUC минимальны (отклонения в тысячных долях), что свидетельствует о высокой структурной устойчивости модели к выбору link-функции.
2. На выбранном recall-ориентированном пороге ($t = 0.35$) Logit и Probit демонстрируют идентичную полноту обнаружения дефолтов ($\text{Recall} = 0.724$). Cloglog показывает незначительное улучшение метрики Brier, однако уступает по параметру Recall.
3. С учетом сопоставимой предиктивной способности, итоговый выбор делается в пользу **Logit-модели**. Это решение обусловлено легкостью интерпретации (возможность оценки Odds Ratios) и соответствием индустриальным стандартам банковского скоринга (Basel PD-models).

9 Тесты спецификации

Методология тестирования. Для обеспечения строгой статистической обоснованности выбранных моделей проводится серия тестов спецификации. Для каждого теста явно формулируется нулевая гипотеза (H_0), рассчитывается статистика критерия и соответствующее p -value. Сводка используемых методов и их аналитическое назначение приведены в таблице ниже.

#	Статистический тест	Проверяемая гипотеза (H_0)	Обоснование выбора
1	LR	Совместная незначимость дополнительных регрессоров во вложенных моделях	Стандартный асимптотически оптимальный тест для MLE-оценок.
2	Wald test	Выполнение линейных ограничений на параметры β	Позволяет тестировать сложные гипотезы (например, равенство разностей коэффициентов) без переоценки модели.
3	Pregibon link-test	Корректность выбранной link-функции	Эффективная диагностика через вспомогательную регрессию Y на $\hat{z}$ и $\hat{z}^2$.
4	Ramsey RESET	Отсутствие пропущенных нелинейностей	Расширение link-теста ($\hat{z}^2, \hat{z}^3$), улавливающее более широкий класс ошибок мисспецификации.
5	Hosmer–Lemeshow (HL)	Корректность калибровки вероятностей $\hat{p}$	Индустриальный стандарт в кредитном скоринге (требование базельских PD-моделей).
6	Holm-Bonferroni correction	Контроль FWER при множественном тестировании ($m = 14$)	Обеспечивает строгий контроль групповой вероятности ошибки I рода при большей мощности, чем классическая поправка Бонферрони.

9.1 LR-тесты вложенных моделей

Тест отношения правдоподобия строится на статистике $LR = -2(\ell_R - \ell_U) \xrightarrow{d} \chi_q^2$, где q — число степеней свободы, ℓ_R и ℓ_U — логарифмы функции правдоподобия ограниченной и неограниченной моделей соответственно.

Сравниваемая пара	$\log L_R$	$\log L_U$	LR	df	p-value
M1 vs M2 (+age ²)	−9871.17	−9869.40	3.54	1	0.060
M1 (grade_ord) vs M4 (dummies)	−9871.17	−9531.79	678.77	5	$1.9 \cdot 10^{-144}$
M4 vs M5 (+ интеракции)	−9531.79	−9402.56	258.46	2	$7.5 \cdot 10^{-57}$

Аналитические выводы.

- **Форма переменной возраста (M1 vs M2):** При уровне значимости 5 % нулевая гипотеза об отсутствии эффекта age² не отвергается ($p = 0.060$). Усложнение модели квадратичным членом статистически не оправдано, что позволяет сохранить более лаконичную спецификацию M1.
- **Форма кредитного рейтинга (M1 vs M4):** Гипотеза о достаточности порядковой шкалы для grade уверенно отвергается. Эффект перехода между рейтингами (например, $A \rightarrow B$ и $F \rightarrow G$) асимметричен в шкале логитов, что строго обосновывает необходимость использования дамми-переменных.
- **Различные взаимодействия (M4 vs M5):** Добавление взаимодействий lpi $\times$ grade и prev $\times$ log income вносит статистически высокосignificant вклад в объясняющую способность модели.

9.2 Тесты Вальда на совместную значимость

Статистика Вальда для тестирования линейных ограничений имеет вид $W = (R\hat{\beta} - q)^\top [R \widehat{\text{Var}}(\hat{\beta}) R^\top]^{-1} (R\hat{\beta} - q) \xrightarrow{d} \chi_r^2$.

Тестируемая гипотеза	df	χ^2	p -value	Вывод
Линейность grade в M4	5	602.54	$5.7 \cdot 10^{-128}$	Отвергается
Совместная значимость intent в M1	5	553.81	$1.9 \cdot 10^{-117}$	Группа значима
Совместная значимость home в M1	3	709.53	$1.8 \cdot 10^{-153}$	Группа значима
Интеракции в M5	2	239.41	$1.0 \cdot 10^{-52}$	Значимы
Совместная незначимость возраста в M2	2	4.98	0.083	Не отвергается

Результаты тестов Вальда согласуются с выводами LR-тестов: возрастные факторы в любой форме оказывают крайне слабое влияние на риск дефолта, тогда как категориальные блоки (цели кредита и статус жилья) обладают мощной совместной объясняющей способностью.

9.3 Диагностика функциональной формы

Pregibon link-test. Оценивается вспомогательная регрессия целевой переменной на предсказанный линейный индекс $\hat{z} = X^\top \hat{\beta}$ и его квадрат $\hat{z}^2$. Если исходная link-функция специфицирована верно, коэффициент при $\hat{z}^2$ должен быть статистически незначим ($H_0 : \alpha_2 = 0$).

Ramsey RESET. Расширяет логику link-теста за счет добавления более высоких степеней: $\text{logit } p_i = X_i^\top \beta + \gamma_2 \hat{z}_i^2 + \gamma_3 \hat{z}_i^3$. Тестируется совместная незначимость новых параметров ($H_0 : \gamma_2 = \gamma_3 = 0$).

Критерий	Модель	Нулевая гипотеза	Статистика	p -value
Pregibon	M1	Корректность link-функции	$z = 8.75$	$2.2 \cdot 10^{-18}$
Pregibon	M5	Корректность link-функции	$z = 18.17$	$8.4 \cdot 10^{-74}$
RESET	M1	Отсутствие нелинейностей	$\chi_2^2 = 77.86$	$1.2 \cdot 10^{-17}$
RESET	M5	Отсутствие нелинейностей	$\chi_2^2 = 356.10$	$4.7 \cdot 10^{-78}$

Анализ результатов. Все гипотезы отвергнуты. Оба теста сигнализируют о наличии остаточной нелинейности. Примечательно, что в модели M5 признаки отклонения от логистической спецификации выражены сильнее, чем в M1, несмотря на то что M5 обладает лучшими метриками качества (AIC/LogL). Эконометрическое объяснение этого парадокса заключается в следующем: включение сложных интеракций улучшает глобальное качество аппроксимации, однако может смещать распределение $\hat{z}$ в области экстремальных значений, где стандартная логистическая форма хуже аппроксимирует реальные хвостовые вероятности. Потенциальным решением для будущих исследований может стать введение сплайнов для $\log(\text{income})$ или полиномов для pri .

9.4 Тест Хосмера-Лемешоу

Для проверки калибровки вероятностей выборка разбивается на $g = 10$ квантилей по предсказанной вероятности $\hat{p}$. В каждой группе сопоставляется эмпирическое и

теоретически ожидаемое число дефолтов. Статистика $HL \xrightarrow{d} \chi^2_{g-2}$ тестирует гипотезу о равенстве предсказанных и фактических частот.

Модель	Статистика HL	df	p-value
M1	104.50	8	$5.1 \cdot 10^{-19}$
M5	362.11	8	$2.3 \cdot 10^{-73}$

Формально тест отвергает гипотезу об идеальной калибровке для обеих моделей. Однако в данном случае мы сталкиваемся с известной проблемой *избыточной мощности* χ^2 -критериев на больших выборках ($n \approx 28\,600$). При таком объеме данных любое, даже экономически незначительное отклонение от идеальной теоретической кривой приводит к отвержению H_0 . В §10.3 мы покажем с помощью визуальных калибровочных графиков, что фактические вероятности лежат предельно близко к биссектрисе, что делает модели пригодными для практического применения.

9.5 Коррекция на множественное тестирование

Поскольку в рамках данного исследования на одной и той же выборке проводится $m = 14$ статистических тестов, возникает проблема множественного сравнения. Без соответствующей коррекции групповая вероятность ошибки первого рода (Family-Wise Error Rate, FWER) существенно превышает номинальный уровень $\alpha = 0.05$. Для контроля FWER мы применяем поправку Холма-Бонферрони, которая является более мощной альтернативой классическому методу Бонферрони.

Алгоритм: p -значения упорядочиваются по возрастанию $p_{(1)} \leq \dots \leq p_{(m)}$, и гипотеза $H_{(k)}$ отвергается до тех пор, пока выполняется условие $p_{(k)} \leq \alpha / (m - k + 1)$.

Тестируемая гипотеза	p_{raw}	Ранг	Порог (Holm)	Статус H_0
Wald joint home в M1	$1.8 \cdot 10^{-153}$	1	0.0036	Отвергается
LR M1 vs M4 (форма grade)	$1.9 \cdot 10^{-144}$	2	0.0038	Отвергается
Wald линейность grade в M4	$5.7 \cdot 10^{-128}$	3	0.0042	Отвергается
Wald joint intent в M1	$1.9 \cdot 10^{-117}$	4	0.0045	Отвергается
Ramsey RESET M5	$4.7 \cdot 10^{-78}$	5	0.0050	Отвергается
Pregibon link-test M5	$8.4 \cdot 10^{-74}$	6	0.0056	Отвергается
Hosmer-Lemeshow M5	$2.3 \cdot 10^{-73}$	7	0.0063	Отвергается
LR M4 vs M5 (интеракции)	$7.5 \cdot 10^{-57}$	8	0.0071	Отвергается
Wald интеракции в M5	$1.0 \cdot 10^{-52}$	9	0.0083	Отвергается
Hosmer-Lemeshow M1	$5.1 \cdot 10^{-19}$	10	0.0100	Отвергается
Pregibon link-test M1	$2.2 \cdot 10^{-18}$	11	0.0125	Отвергается
Ramsey RESET M1	$1.2 \cdot 10^{-17}$	12	0.0167	Отвергается
LR M1 vs M2 (age^2)	0.0600	13	0.0250	Не отвергается
Joint Wald $\text{age} = \text{age}^2 = 0$ (M2)	0.0830	14	0.0500	Не отвергается

Вывод. Даже при строгом контроле FWER на уровне 5%, 12 из 14 тестов сохраняют свою статистическую значимость. Незначимыми остаются исключительно тесты, связанные с квадратичной формой возраста. Это дает нам надежные статистические основания для использования дамми-переменных рейтинга, включения интеракций и интерпретации категориальных предикторов.

9.6 Резюме по результатам тестирования спецификаций

Специфика эконометрического моделирования на выборках большого объема ($n > 20\,000$) заключается в том, что статистическая значимость отклонений (p -value $\approx$

0) не всегда тождественна их экономической или практической значимости. Тесты RESET, Pregibon и HL обладают высокой чувствительностью к малейшим локальным ошибкам в спецификации. В таких условиях формальные критерии должны интерпретироваться совместно с метриками предсказательной способности и графическими диагностиками.

Исходя из комбинации статистических свойств и интерпретируемости, **М5 принимается как лучшая модель для анализа сложных эффектов** (наивысшие показатели AIC и Out-of-sample метрик), а **М1 — как надежная базовая спецификация** для прямой интерпретации базовых факторов риска.

10 Оценка предсказательной способности

Считаем набор метрик для М1 и М5. Все метрики ниже посчитаны на out-of-sample test-выборке (см. §7.3).

10.1 Метрики качества и формулы

Brier score $BS = \frac{1}{n} \sum (Y_i - \hat{p}_i)^2 \in [0, 1]$ — средний квадрат ошибки прогноза вероятности, меньше — лучше.

Log-loss $LL = -\frac{1}{n} \sum [Y_i \log \hat{p}_i + (1 - Y_i) \log(1 - \hat{p}_i)]$.

AUC $= \Pr(\hat{p}(X^{(1)}) > \hat{p}(X^{(0)}))$, **Gini** $= 2 \cdot \text{AUC} - 1$.

PR-AUC — площадь под precision-recall кривой; полезна при дисбалансе классов (что соответствует нашему случаю) (baseline $= \bar{Y}$).

KS-statistic $= \max_t |\hat{F}_1(t) - \hat{F}_0(t)|$ — максимальное вертикальное расстояние между CDF $\hat{p}$ для классов $Y = 0$ и $Y = 1$.

Calibration-in-the-large CITL $= \bar{Y} - \bar{\hat{p}}$, **calibration slope** — наклон α_1 в регрессии $\text{logit } Y \sim \alpha_0 + \alpha_1 \cdot \text{logit } \hat{p}$ (идеал $\alpha_1 = 1$).

Метрика	М1	М5	Baseline
Brier ↓	0.1054	0.0975	0.1697
log-loss ↓	0.3448	0.3284	0.5226
AUC ↑	0.8694	0.8808	0.5000
Gini ↑	0.7387	0.7616	0.0000
PR-AUC ↑	0.7111	0.7485	0.2166
KS-Statistic ↑	0.5835	0.6266	0.0000
McFadden R^2 ↑	0.3403	0.3716	0.0000

Таблица 10: Сравнение качества М1 и М5.

Мы видим, что М5 равномерно лучше М1 (то есть лучше по всем метрикам).

10.2 ROC и Precision-Recall кривые




Рис. 7: ROC и Precision-Recall кривые M1 vs M5 (out-of-sample, test). M5 даёт более высокий AUC и PR-AUC во всём диапазоне порогов.

Интерпретация. ROC-кривая обеих моделей лежит выше диагонали. Метрика ROC-AUC больше для модели M5 и по графику видно, что красная кривая, соответствующая M5, лежит ближе к верхнему левому углу, что также свидетельствует о более хорошем качестве модели. Precision-Recall кривая показывает, что при оптимальном recall (который нас устраивают и который нас получался на кросс-валидации, то есть в диапазоне 0.6-0.7) значение precision выше у модели M5, чем у M1. Поскольку измерения проводятся на тестовой выборке, это означает, что нам действительно удалось выявить закономерность в данных, а не просто получить переобучение.

10.3 Calibration plot




Рис. 8: Calibration plots для M1 и M5 (out-of-sample, test). Точки близки к 45°-линии — модели хорошо калиброваны.

Что показывает calibration plot. Точки на 45°-линии означают идеальную калибровку: “когда модель говорит 30 %, реально дефолтит 30 % группы”. Это соответствует

совпадению децилей распределения вероятностей, которые дает модель и статистического распределения вероятностей (долей). Отклонения от линии — систематические смещения.

Далее проведем некоторые статистические тесты, которые позволят нам точно интерпретировать графики. **Интерпретация:**

- **Calibration slope:** M1 — 0.996 ± 0.030 , M5 — 0.984 ± 0.029 . Оба значения статистически неотличимы от 1, что означает: модели правильно “растягивают” вероятности от 0 до 1, без систематического сжатия или растяжения.
- **CITL** (calibration-in-the-large) ≈ 0 в обеих моделях — среднее предсказанное соответствует среднему наблюдаемому.
- Визуально точки лежат *практически на диагонали* во всём диапазоне $\hat{p}$, особенно в области малых $\hat{p}$ (< 0.2).
- Видно, что модель M5 старается занижить вероятность дефолта для вероятностей $\approx 0.1 - 0.5$, что простительно в кредитном скоринге, поскольку отвечает нашему главному желанию — не давать в долг тем, кто не может этот долг вернуть. При этом, банк может с большей уверенностью доверять нашей модели, зная, что она оставляет некоторый “запас прочности” заемщику.

Вывод по калибровке. И M1, и M5 пригодны для прямой интерпретации $\hat{p}$ как PD; для PD-калибровки под Basel дополнительная пост-калибровка (Platt scaling, isotonic regression) не обязательна.

10.4 KS-statistic

Что это и зачем. KS — стандарт credit scoring (используется в Basel-моделях). Идея: если модель хорошо разделяет классы, распределения $\hat{p}$ для $Y = 0$ и $Y = 1$ должны быть *максимально далеки* друг от друга. KS — максимальное вертикальное расстояние между их CDF.

Зачем именно в кредитном скоринге. В банке часто работают с правилом отсечения “одобрять при $\hat{p} < t^*$ ”. Чтобы выбрать оптимальный t^* , важно знать, в какой точке распределения хороших и плохих наиболее различаются. KS даёт ровно эту точку.




Рис. 9: Эмпирические CDF $\hat{p}$ для классов $Y = 0$ (синий) и $Y = 1$ (красный). KS-статистика — максимальный вертикальный разрыв.

Интерпретация. KS-максимум для M1 достигается в районе $\hat{p} \approx 0.18$, для M5 — в районе $\hat{p} \approx 0.30$. То есть для лучшей модели M5 точка наибольшего разделения классов *лежит вблизи выбранного рабочего порога* $t = 0.35$ из §7.3 — это дополнительное косвенное подтверждение, что наш recall-ориентированный порог выбран близко к статистически оптимальному. Для credit scoring $KS > 0.4$ считается “приемлемо”, $KS > 0.6$ — “хорошо”. Наши значения (0.58 для M1, 0.63 для M5) попадают в верхнюю категорию.

10.5 Lift и Gain charts

Что это и зачем. Заёмщики ранжируются по $\hat{p}$ (от высокого риска к низкому), и считаются:

- **Gain в топ- k %** — какая доля *всех дефолтов* попадает в эти k % заёмщиков с самым высоким $\hat{p}$. Идеальная модель: в топ- $\bar{Y} \cdot 100$ % ≈ 22 % попадают 100 % дефолтов.
- **Lift в топ- k %** — во сколько раз больше дефолтов в этих k %, чем при случайной выборке такого же размера. Lift = 1 — случайно; Lift > 2 — модель работает хорошо.

Зачем именно в credit scoring. Если банк хочет автоматически отказать 20 % самых плохих заявок (без дальнейшего рассмотрения), Gain в топ-20 % говорит, какую долю дефолтников он отсечёт этим решением. Это прямая бизнес-интерпретация.




Рис. 10: Gain и Lift charts для M1 и M5 (out-of-sample, test).

Конкретные числа.

	Top-10 %		Top-20 %	
	Lift	Gain	Lift	Gain
M1	3.87	38.7 %	—	61.8 %
M5	3.98	39.8 %	—	65.8 %

Интерпретация.

- *Top-10 % Gain* $\approx 40\%$ — банк, отказывающий всем заявкам с $\hat{p}$ в верхних 10%, отсёк бы 40% реальных дефолтников.
- *Top-10 % Lift* ≈ 3.9 — в этих 10% концентрация дефолтов в 3.9 раза выше, чем в общей выборке.
- *Top-20 % Gain* $\approx 65\%$ для М5 — удвоение группы отказов с 10 до 20% даёт 25 п.п. дополнительного покрытия дефолтов.

Вывод по всему параграфу 10 М5 равномерно лучше М1 по всем метрикам качества (Brier, log-loss, AUC, Gini, PR-AUC, KS, R²). Обе модели хорошо калиброваны (slope ≈ 1 , CITL ≈ 0), что делает $\hat{p}$ интерпретируемой как PD. Бизнес-метрики Lift/Gain показывают, что в топ-10% концентрация дефолтов в 3.9 раза выше базы — модель работает как полезный фильтр.

11 Устойчивость и идентификация модели.

Показываем устойчивость основных выводов к вариациям предпосылок.

11.1 Сравнение типов стандартных ошибок

Зачем сравниваем разные SE. Стандартные ошибки в логите можно считать несколькими способами в зависимости от того, какие предположения об ошибках выполняются. Цель раздела — показать, на что устойчива значимость наших ключевых коэффициентов.

Различные оценки ковариационной матрицы:

- **Classical** (model-based): $\widehat{\text{Var}}(\hat{\beta}) = (X^T W X)^{-1}$, $W = \text{diag}(\hat{p}_i(1 - \hat{p}_i))$. Корректна *только при правильной спецификации* (точная link-функция, правильные регрессоры). Поскольку Pregibon в §9 отвергает идеальность link, classical SE могут быть смещены — нужны robust-альтернативы.
- **HC1** (Huber–White, sandwich) с поправкой $n/(n - k)$ — консистентна при гетероскедастичности относительно $p(1 - p)$. *Наша основная схема.*
- **HC3** — модификация HC1 с поправкой $1/(1 - h_{ii})^2$ для leverage points.
- **Cluster-by-grade** ($G = 7$) — учитывает корреляцию ошибок внутри grade-группы. *Только как стресс-тест!* Формально применение CRVE при $G = 7$ некорректно (теория требует $G \rightarrow \infty$, на практике $G \geq 30$ –50); кроме того, `loan_grade` — *эндогенный* признак (банк сам присваивает рейтинг по X). Поэтому cluster-SE приведены только для прозрачности, не для содержательных выводов.

Признак	$\hat{\beta}$	SE classic	SE HC1	SE HC3	SE cluster
<code>loan_percent_income</code>	8.0785	0.3915	0.4247	0.4247	0.6004
<code>log_income</code>	−1.0546	0.0790	0.0904	0.0904	0.2525
<code>grade_ord</code>	0.9268	0.0187	0.0194	0.0194	0.1454
<code>home_OWEN</code>	−1.6983	0.1081	0.1075	0.1075	0.5012
<code>home_RENT</code>	0.7146	0.0421	0.0438	0.0438	0.1525
<code>prev_default</code>	−0.1187	0.0469	0.0468	0.0468	0.1928

Вывод. НС1 и НС3 вообще значительно не различаются — выбор между ними не критичен. Что касается классических стандартных ошибок, то нельзя однозначно сказать — в каких ситуациях она лучше, а в каких хуже, так как ошибки на коэффициентах при разных признаках где-то выше у классической модели, где-то у НС1 и НС3. Для финальных выводов используем НС1, как и предполагалось изначально, как компромиссный вариант, который еще и принят в кредитном скоринге.

11.2 Bootstrap-доверительные интервалы

Зачем bootstrap. Параметрические CI ($\hat{\beta} \pm 1.96 \cdot SE$) опираются на асимптотическую нормальность $\hat{\beta}$, которая не всегда выполнена в конечных выборках, особенно для коэффициентов с большими стандартными ошибками или сильно скошенных регрессоров. Bootstrap даёт *непараметрические* CI без этого допущения: делаем 200 ресэмплов с возвращением, на каждом переоцениваем М1 и берём перцентили распределения $\hat{\beta}_j^{(b)}$.

Что мы получаем. Если bootstrap-CI совпадают с асимптотическими — это *дополнительное* свидетельство, что асимптотическое нормальное приближение применимо. Если расходятся — следует доверять bootstrap (особенно если асимптотический $\hat{\beta}$ скошен).

Признак	$\hat{\beta}$	asyp lo	asyp hi	boot lo	boot hi
loan_percent_income	8.079	7.246	8.911	7.257	8.891
log_income	-1.055	-1.232	-0.877	-1.231	-0.884
grade_ord	0.927	0.889	0.965	0.892	0.964
home_OWN	-1.698	-1.909	-1.488	-1.904	-1.510
home_RENT	0.715	0.629	0.801	0.641	0.824
prev_default	-0.119	-0.211	-0.027	-0.205	-0.028

Таблица 11: Bootstrap (200 ресэмплов) vs асимптотические 95 % CI. Совпадение границ во 2-м знаке свидетельствует о применимости нормальной асимптотики при $n = 28\,631$.

Содержательный вывод. Bootstrap- и асимптотические CI практически совпадают для всех ключевых коэффициентов — знаки и значимости одинаковы. Особенно важно для prev_default: знак “—” в М1 устойчив в обоих типах CI, что усиливает интерпретацию, теперь мы понимаем, что это реальное свойство наших конкретных данных, а не ошибка, связанная с асимптотикой.

11.3 Sensitivity к порогу возраста

Признак	age $\leq$ 60 ($n = 28\,578$)	age $\leq$ 80 ($n = 28\,631$)	age $\leq$ 100 ($n = 28\,632$)	age $\leq$ 120 ($n = 28\,632$)
loan_percent_income	8.116	8.079	8.078	8.078
log_income	-1.047	-1.055	-1.055	-1.055
grade_ord	0.928	0.927	0.927	0.927
home_OWN	-1.699	-1.698	-1.698	-1.698
home_RENT	0.715	0.715	0.715	0.715
prev_default	-0.120	-0.119	-0.119	-0.119

Вывод. Коэффициенты практически не меняются при пороге ≥ 80 — наблюдений выше 80 в данных всего несколько штук, и они не влияют на оценки. Решение $\text{age} \leq 80$ робастно.

11.4 Sensitivity к обработке пропусков

Это формальная проверка решения из §2.3. Сравниваем три стратегии: listwise drop (основа), median imputation, dummy-индикатор пропуска.

Признак	drop ($n = 28\,631$)	median ($n = 32\,572$)	indicator ($n = 32\,572$)
loan_percent_income	8.079	7.837	7.936
log_income	-1.055	-1.137	-1.094
grade_ord	0.927	0.909	0.914
home_OWN	-1.698	-1.605	-1.627
home_RENT	0.715	0.704	0.714
prev_default	-0.119	-0.129	-0.129

Вывод. Коэффициенты ключевых регрессоров устойчивы к стратегии пропусков — расхождения в пределах 5–10 %. Это означает, что механизм пропусков `loan_int_rate` и `person_emp_length` близок к MCAR/MAR относительно наблюдаемых характеристик заёмщика, и listwise drop (отбрасывание строк с пропусками) является приемлемым решением. *Это формально подтверждает обоснование из §2.3.*

11.5 Подвыборки — структурные сдвиги

Признак	все ($n = 28\,631$)	grade A–C ($n = 24\,246$)	grade D–G ($n = 4\,385$)	lpi < 0.2 ($n = 18\,920$)	lpi ≥ 0.2 ($n = 9\,711$)
loan_percent_income	8.079	8.780	3.792	-2.938	5.263
log_income	-1.055	-1.452	-0.806	-1.533	-4.417
grade_ord	0.927	0.409	0.611	1.147	0.785
home_OWN	-1.698	-1.548	-3.503	-2.281	-1.375
home_RENT	0.715	0.839	1.236	0.062	1.814
prev_default	-0.119	-0.062	+0.070	-0.147	-0.104

Наблюдения.

- **Нелинейность lpi подтверждена:** в подгруппе низкой нагрузки ($\text{lpi} < 0.2$) коэффициент *отрицательный* (-2.94), при высокой (≥ 0.2) — резко *положительный* ($+5.26$). Именно зависимость такого плана ловили тест Рамсея и Прегибона, именно поэтому интеракция $\text{lpi} \times \text{grade}$ значима в М5.
- **prev_default:** в A–C знак отрицательный (-0.06 , а значит канал отбора (selection-канал, то есть искажение оценок из-за случайного отбора наблюдений) *силён*), в D–G знак *возвращается положительному* ($+0.07$, среди “плохих” заёмщиков канал отбора слабее). Это доказательство интерпретации reject-inference из §8.

11.6 Мультиколлинеарность и смещение

А. Мультиколлинеарность $\text{loan_int_rate} \leftrightarrow \text{loan_grade}$. В М6 (с включённой ставкой, для которой $\text{VIF}_{\text{rate}} \approx 7.85$) коэффициент grade_ord падает почти в два раза (с 0.93 до 0.53) — это проявление коллинеарности: две переменные “забирают” друг у друга часть дисперсии. Решение в основной спецификации — исключить loan_int_rate , оставив grade .

В. Selection bias / reject inference. Мы наблюдаем только заёмщиков, *которым уже выдали кредит* ($S = 1$). Поэтому

$$\hat{p}_i = \widehat{\Pr}(Y_i = 1 \mid X_i, S_i = 1) \neq \Pr(Y_i = 1 \mid X_i).$$

Если процедура одобрения банка систематически исключает заёмщиков, которые наиболее рискованные (а так и есть), эффекты в выборке отличаются от реальной жизни. Формальное решение требует данных по отказам, что мы оставляем для будущей работы.

С. Simpson’s paradox для prev_default . Главный сюжет работы (§8): знак $\hat{\beta}$ отрицателен в М1 (−0.119), нулевой в М4 (с дамми grade), и положительный +1.13 в М7 (без grade). Подвыборки в §11.5 показывают, что в А–С канал отбора (selection-канал) доминирует (знак −), в D–G — привычный signal-канал (знак +) (возможность заёмщика повлиять на решение банка, предоставив дополнительную информацию, которая снижает асимметрию информации). Это наблюдение, полученное в рамках исследования информации об одобренных заёмщиках, которая меньше, чем общее количество заявок на займ.

Заключение

Основной задачей настоящей работы являлось построение эконометрической модели вероятности дефолта заёмщика, сочетающей в себе высокую предиктивную способность с прозрачной бизнес-логикой и строгим статистическим обоснованием. В ходе исследования был проведен полный цикл анализа данных: от очистки выбросов до тестирования спецификаций на предмет пропущенных нелинейностей и смещения отбора.

Методология и основные этапы моделирования:

- 1. Учет специфики данных.** На этапе первичного анализа были зафиксированы структурные ограничения выборки, ключевыми из которых являются аномально высокая доля дефолтов (около 21.8%) и наличие сильного скрытого фильтра (оцениваются данные только по *уже одобренным* заявкам). Все последующие выводы и тесты интерпретировались с поправкой на данные эффекты.
- 2. Пошаговое тестирование спецификаций.** Для выявления истинной формы зависимостей была оценена серия из семи логит-моделей (М1–М7), а также проведено сравнение альтернативных функций связи (Logit, Probit, Cloglog). Это позволило изолированно оценить чувствительность коэффициентов к включению новых регрессоров и интеракций.
- 3. Проверка на устойчивость.** Статистическая надежность результатов подтверждена расчетом робастных стандартных ошибок (HC1/HC3), построением непараметрических бутстрап-интервалов и тестированием структурных сдвигов на подвыборках.

4. **Калибровка бизнес-метрики.** Вместо использования стандартного порога классификации ($t = 0.5$), оптимальная точка отсечения была смещена до $t = 0.35$. Это решение продиктовано асимметрией функции потерь в кредитном скоринге, где цена пропуска дефолта (FN) существенно превышает издержки от необоснованного отказа (FP).

Ключевые эмпирические результаты:

- **Фундаментальные маркеры риска.** Наибольшей объясняющей способностью ожидаемо обладает внутренний кредитный рейтинг заемщика (`grade`). Выявлен выраженный нелинейный эффект долговой нагрузки: риск дефолта начинает резко возрастать при превышении порога `lpi` в 20 %. Напротив, наличие собственной недвижимости без обременения (`home_OWN`) и образовательные/коммерческие цели кредита выступают надежными индикаторами финансовой стабильности.
- **Идентификация смещения отбора.** Анализ переменной наличия прошлых дефолтов (`prev_default`) продемонстрировал классический эффект смещенной выборки. В базовой модели M1 факт дефолта в прошлом парадоксально снижал вероятность нового дефолта ($\hat{\beta} = -0.119$). Однако при исключении из модели рейтинга (спецификация M7) знак эффекта сменился на ожидаемо положительный ($\hat{\beta} = +1.126$). Это доказывает, что попадание клиента с плохой историей в выборку одобренных заявок означает наличие у него сильных ненаблюдаемых преимуществ, которые модель первоначально улавливала как позитивный сигнал.
- **Предиктивное качество.** Итоговая спецификация с учетом нелинейностей и интеракций (M5) продемонстрировала высокие метрики качества на тестовой выборке ($AUC = 0.883$, $KS \approx 0.63$). Графики калибровки подтвердили совпадение предсказанных и фактических вероятностей, а анализ Lift-кривой показал, что в 10 % наиболее подозрительных заявок концентрация реальных дефолтов почти в 4 раза превышает базовую частоту.

Ограничения модели и направления для дальнейшего анализа:

1. **Остаточные нелинейности.** Статистические критерии (RESET, Pregibon) сигнализируют о наличии локальных отклонений от логистической формы. Перспективным улучшением модели является переход от простых логарифмов к использованию кубических сплайнов для точного моделирования хвостовых распределений дохода и стажа.
2. **Проблема эндогенности ставки.** Процентная ставка была исключена из итоговой спецификации из-за почти полной коллинеарности с рейтингом. Для оценки истинной эластичности риска по процентной ставке могут быть использованы инструментальные переменные.
3. **Отсутствие временной структуры.** Ввиду отсутствия временных меток в исходных данных, проверка устойчивости модели к макроэкономическим шокам остается открытым вопросом, требующим применения методов анализа панельных данных.

Таким образом, итогом исследования является статистически корректная, хорошо интерпретируемая эконометрическая модель, детально описывающая механизм формирования риска дефолта с учетом структурных особенностей предоставленной выборки.